Reporte ejecutivo

Segmentación de clientes mediante Machine Learning no supervisado

Generado: 2026-11-11 20:12 · Periodo: 2010-12-01 a 2011-12-09

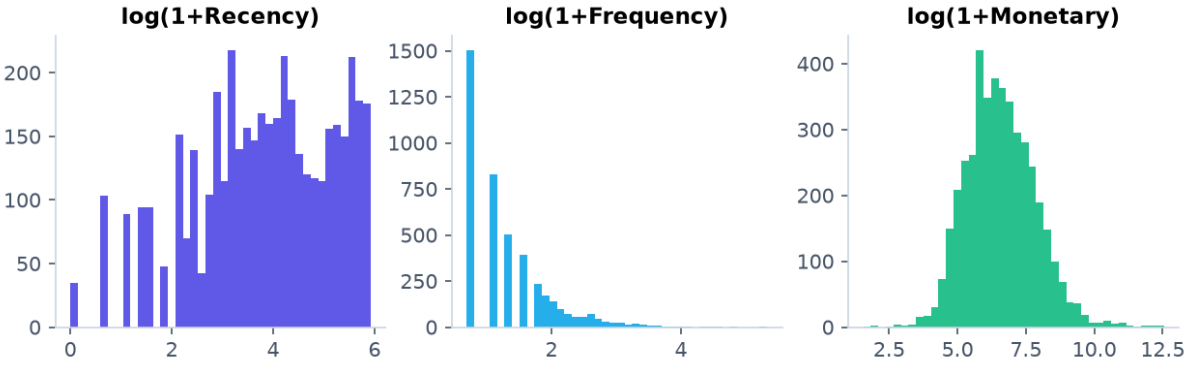
1. Resumen

Se analizaron **4,334** clientes con **18,402** facturas y ingresos totales de **£8,737,228**. El mejor modelo según el ranking compuesto fue **K-Means** ({'k': 4}), que identifica **4** segmentos con silhouette de **0.237**.

2. Calidad y limpieza de datos

Se partió de 541,909 registros y quedaron 391,150 compras válidas. Cada paso fue registrado:

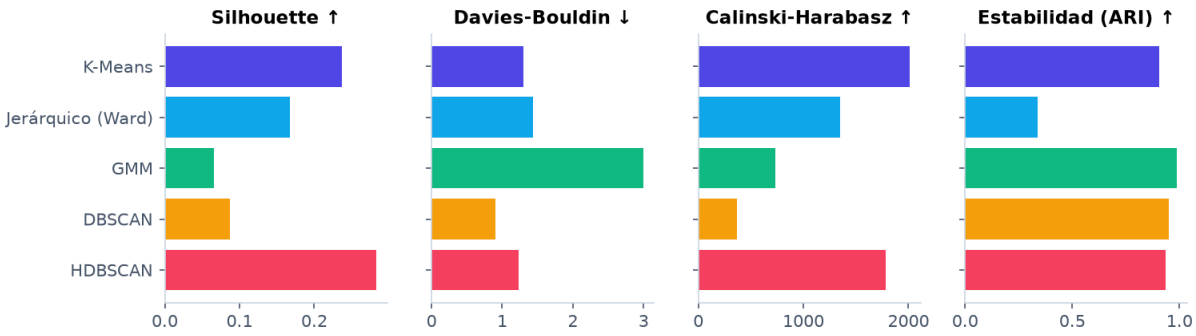
paso	filas_antes	filas_despues	eliminadas
Duplicados exactos	541909	536641	5268
Sin CustomerID	536641	401604	135037
Códigos no-producto	401604	399689	1915
Cancelaciones (facturas 'C')	399689	391183	8506
Cantidad <= 0	391183	391183	0
Precio unitario <= 0	391183	391150	33



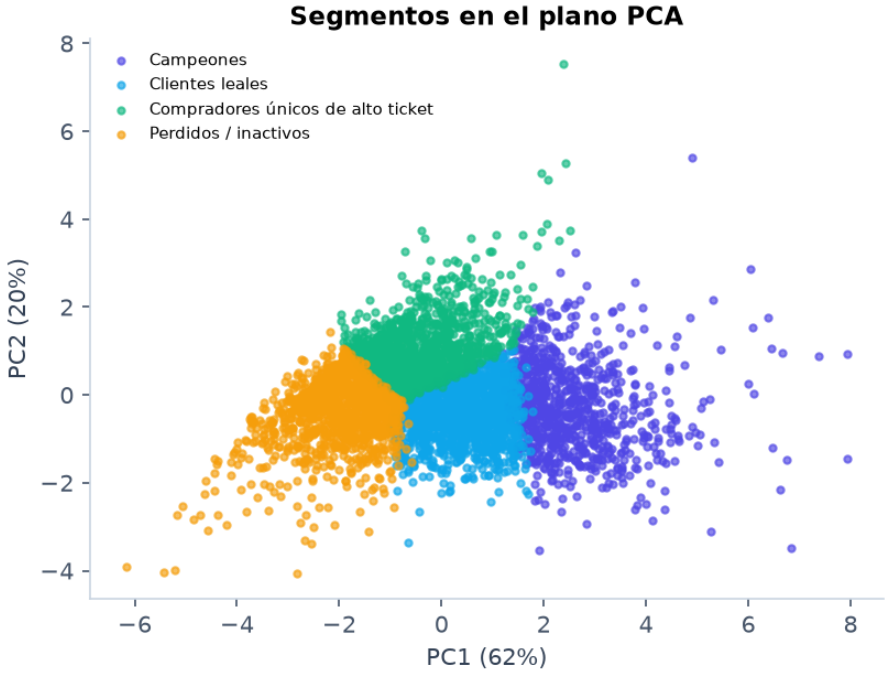
3. Comparación de algoritmos

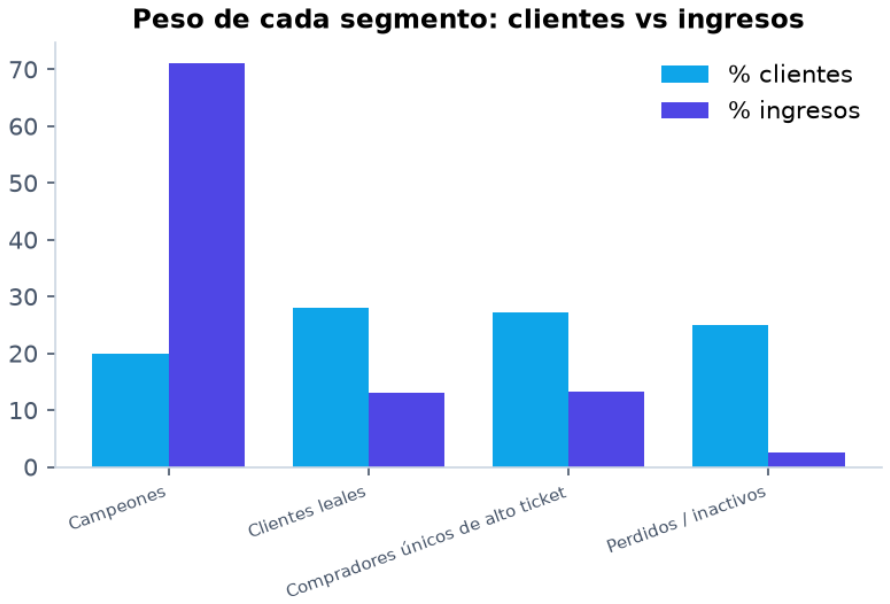
Se compararon K-Means, Jerárquico (Ward), GMM, DBSCAN y HDBSCAN con métricas internas y estabilidad (ARI en submuestras). Se consideran elegibles los modelos con 4-8 grupos y ≤10% de ruido.

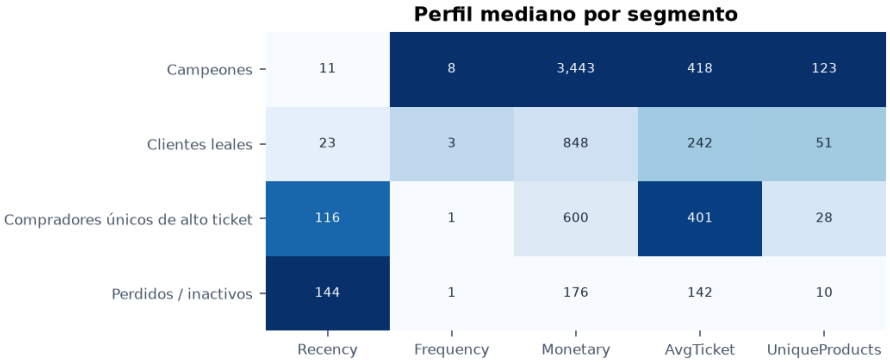
modelo	n_clusters	ruido_pct	silhouette	davies_bouldin	calinski_harabasz	estabilidad_ari	elegible
K-Means	4	0.0	0.237	1.3	2014.979	0.907	True
Jerárquico (Ward)	5	0.0	0.167	1.43	1348.589	0.337	True
GMM	6	0.0	0.065	2.996	735.325	0.988	True
DBSCAN	6	7.25	0.087	0.905	364.922	0.95	True
HDBSCAN	2	20.58	0.283	1.228	1781.144	0.937	False


Silhouette ↑
Davies-Bouldin ↓
Calinski-Harabasz ↑
Estabilidad (ARI) ↑
K-Means
Jerárquico (Ward)
GMM
DBSCAN
HDBSCAN
0.0
0.1
0.2
0
1
2
3
0
1000
2000
0.0
0.5
1.0

4. Segmentos de clientes







5. Perfiles y acciones recomendadas

Campeones — 860 clientes (19.8%) · 71.2% de los ingresos

Mediana: recencia 11 días · frecuencia 8 · gasto £3,443 · ticket £418

Acción: Programa VIP, acceso anticipado a novedades y pedidos personalizados. Proteger la relación: son la base de ingresos.

Clientes leales — 1,216 clientes (28.1%) · 13.1% de los ingresos

Mediana: recencia 23 días · frecuencia 3 · gasto £848 · ticket £242

Acción: Venta cruzada, programa de puntos y descuentos por volumen para aumentar el ticket medio.

Compradores únicos de alto ticket — 1,178 clientes (27.2%) · 13.3% de los ingresos

Mediana: recencia 116 días · frecuencia 1 · gasto £600 · ticket £401

Acción: Compraron una sola vez un pedido grande y no volvieron: contacto comercial directo, oferta de recompra y revisión de su experiencia.

Perdidos / inactivos — 1,080 clientes (24.9%) · 2.5% de los ingresos

Mediana: recencia 144 días · frecuencia 1 · gasto £176 · ticket £142

Acción: Campaña de bajo costo de 'te extrañamos'; no invertir en retención intensiva.

6. Mejor modelo y conclusiones

El mejor modelo para este proyecto es **K-Means** {'k': 4}: obtiene el mejor ranking compuesto entre los modelos elegibles (silhouette 0.237, Davies-Bouldin 1.30, Calinski-Harabasz 2,015, estabilidad 0.91, sin ruido), y además produce segmentos que el negocio puede entender y accionar.

1. Es posible segmentar a los clientes sin etiquetas previas: se identificaron **4 segmentos** con K-Means.

2. El valor está muy concentrado: **Campeones** (20% de clientes) genera 71% de los ingresos.

3. No hay un único algoritmo «mejor» en todas las métricas; la elección depende del objetivo. Para marketing, K-Means ofrece el mejor equilibrio.

4. Los datos forman un continuo (silhouette 0.24); por eso se priorizó la interpretabilidad y la estabilidad sobre maximizar una métrica.

5. La combinación de RFM + ticket medio + variedad de productos permite distinguir perfiles que RFM por sí solo no separaría (p. ej., compradores únicos de ticket alto).

Hallazgos principales

Datos: Se partió de 541,909 registros y quedaron 391,150 compras válidas de 4,334 clientes. 25% de las filas no tenía CustomerID y se descartó.

Concentración del valor: El 20% de los clientes que más gastan genera ~75% de los ingresos. El gasto medio es 3.0 veces la mediana: pocos clientes muy grandes elevan el promedio.

Recompra: 35% de los clientes compró una sola vez en el periodo: la fidelización es la mayor oportunidad.

Estacionalidad: Las ventas suben hacia el final del año; el pico es 2011-11.

Devoluciones: En promedio, 10.1% de las facturas de un cliente son cancelaciones.

Segmentos descubiertos: Campeones (20% clientes, 71% ingresos); **Clientes leales** (28% clientes, 13% ingresos); **Compradores únicos de alto ticket** (27% clientes, 13% ingresos); **Perdidos / inactivos** (25%

clientes, 2% ingresos).

Calidad de la estructura: El silhouette (0.24) es moderado y el acuerdo entre algoritmos es bajo (ARI 0.30): los clientes forman un continuo, no grupos aislados. Los segmentos son útiles como convención de negocio, no como categorías «naturales».

7. Limitaciones

• Un solo minorista del Reino Unido y solo 12 meses: no se pueden generalizar los resultados ni medir ciclos anuales completos.

• Gran presencia de mayoristas: sus compras elevan el gasto y condicionan la separación entre grupos.

• No hay etiquetas reales para validar externamente; solo métricas internas y estabilidad.

• Los segmentos describen comportamiento pasado; deben recalcularse periódicamente (el dashboard permite re-ejecutar el pipeline).